Московский государственный технический университет имени Н. Э. Баумана Кафедра «Системы обработки информации и управления»

Рубежный контроль №1 по курсу «Методы машинного обучения»

Выполнил:

Студент ИУ5-24М

Черната Н. С.


Задание

Для заданного набора данных проведите обработку пропусков в данных. Какие способы обработки пропусков в данных для категориальных и количественных признаков Вы использовали? Какие признаки Вы будете использовать для дальнейшего построения моделей машинного обучения и почему? Для заданного набора данных произведите масштабирование данных и преобразование категориальных признаков в количественные. Какие методы Вы использовали для решения задачи и почему?

Набор данных:

https://www.kaggle.com/karangadiya/fifa19

```
In [1]: import numpy as np
          import pandas as pd
import seaborn as sns
          import matplotlib.pyplot as plt
%matplotlib inline
          sns.set(style="ticks")
          Загрузка данных
 In [3]: data = pd.read_csv('MMO/fifa19/data.csv', sep=",")
In [74]: data.shape
Out[74]: (18207, 89)
 In [5]: data.dtypes
 Out[5]: Unnamed: 0
          TD
                                int64
                                int64
                               object
          GKHandling
                            float64
          GKKicking
GKPositioning
                              float64
                              float64
          GKReflexes
Release Clause
                             float64
                               object
          Length: 89, dtype: object
 In [6]: data.isnull().sum()
 Out[6]: Unnamed: 0
          Name
                                 0
          Age
```



Импьютация

In [15]: for col in data_num:

plt.hist(data[col], 50)
plt.xlabel(col)
plt.show()


Обработка пропусков в числовых данных


```
In [12]: data_new_3 = data.fillna(0)
    data_new_3.head()
Out[12]:
                Unnamed:
0
                                        Name Age
                                                                                           Photo Nationality
                                                                                                                                          Flag Overall Potential
                                                                                                                                                                      FC
Barcelona
             0
                          0 158023
                                      L. Messi
                                                  31 https://cdn.sofifa.org/players/4/19/158023.png
                                                                                                    Argentina https://cdn.sofifa.org/flags/52.png
                                      Cristiano
Ronaldo
             1
                          1 20801
                                                  33 https://cdn.sofifa.org/players/4/19/20801.png
                                                                                                      Portugal https://cdn.sofifa.org/flags/38.png
                                                                                                                                                      94
                                                                                                                                                                94
                                                                                                                                                                        Juventus
                                                                                                                                                                     Paris Saint-
Germain
                                       Neymar
             2
                          2 190871
                                                  26 https://cdn.sofifa.org/players/4/19/190871.png
                                                                                                        Brazil https://cdn.sofifa.org/flags/54.png
                                                                                                                                                                 93
                                                                                                                                                                     Manchester
             3
                          3 193080 De Gea
                                                 27 https://cdn.sofifa.org/players/4/19/193080.png
                                                                                                        Spain https://cdn.sofifa.org/flags/45.png
                                                                                                                                                      91
                                                                                                                                                                93
                                       K. De
Bruyne
                                                                                                                                                                 92 Manchester
                          4 192985
                                                  27 https://cdn.sofifa.org/players/4/19/192985.png
                                                                                                      Belgium https://cdn.sofifa.org/flags/7.png
            5 rows × 89 columns
            4
In [13]: num_cols = []
            for col in data.columns:
                 ten at datacommis.


# Количество пустых значений

temp_null_count = data[data[col].isnull()].shape[0]

dt = str(data[col].dtype)
                 if temp_null_count>0 and (dt=='float64' or dt=='int64'):
                      num_cols.append(col)
                      temp_perc = round((temp_null_count / total_count) * 100.0, 2)
print('Колонка {}. Тип данных {}. Количество пустых значений {}, {}%.'.format(col, dt, temp_null_count, temp_perc))
            Колонка International Reputation. Тип данных float64. Количество пустых значений 48, 0.26%. Колонка Weak Foot. Тип данных float64. Количество пустых значений 48, 0.26%.
  In [14]: data_num = data[num_cols]
              data_num
 Out[14]:
                       International Weak
Reputation Foot
                                             Skill
Moves
                                                     Jersey Crossing Finishing HeadingAccuracy ShortPassing Volleys Dribbling ... Penalties Composure Marking Star
                   0
                                5.0
                                       4.0
                                                4.0
                                                         10.0
                                                                    84.0
                                                                                95.0
                                                                                                   70.0
                                                                                                                   90.0
                                                                                                                            86.0
                                                                                                                                       97.0
                                                                                                                                                      75.0
                                                                                                                                                                    96.0
                                                                                                                                                                              33.0
                                                          7.0
                                5.0
                                        4.0
                                                5.0
                                                                    84.0
                                                                                94.0
                                                                                                   89.0
                                                                                                                   81.0
                                                                                                                            87.0
                                                                                                                                       88.0
                                                                                                                                                      85.0
                                                                                                                                                                    95.0
                                                                                                                                                                              28.0
                   2
                                5.0
                                        5.0
                                                5.0
                                                          10.0
                                                                    79.0
                                                                                87.0
                                                                                                   62.0
                                                                                                                   84.0
                                                                                                                            84.0
                                                                                                                                       96.0
                                                                                                                                                      81.0
                                                                                                                                                                    94.0
                                                                                                                                                                              27.0
                   3
                                4.0
                                        3.0
                                                1.0
                                                          1.0
                                                                     17.0
                                                                                13.0
                                                                                                   21.0
                                                                                                                   50.0
                                                                                                                            13.0
                                                                                                                                        18.0
                                                                                                                                                      40.0
                                                                                                                                                                    68.0
                                                                                                                                                                              15.0
                                4.0
                                                4.0
                                                          7.0
                                                                    93.0
                                                                                82.0
                                                                                                   55.0
                                                                                                                   92.0
                                                                                                                           82.0
                                                                                                                                       86.0
                                                                                                                                                      79.0
                                                                                                                                                                    88.0
                                                                                                                                                                              68.0
               18202
                                1.0
                                       2.0
                                                2.0
                                                         22.0
                                                                    34.0
                                                                                38.0
                                                                                                    40.0
                                                                                                                   49.0
                                                                                                                           25.0
                                                                                                                                       42.0 ...
                                                                                                                                                      43.0
                                                                                                                                                                    45.0
                                                                                                                                                                              40.0
               18203
                                 1.0
                                        2.0
                                                2.0
                                                         21.0
                                                                    23.0
                                                                                52 0
                                                                                                   52.0
                                                                                                                   43.0
                                                                                                                            36.0
                                                                                                                                       39.0
                                                                                                                                                      43.0
                                                                                                                                                                    42.0
                                                                                                                                                                              22 0
               18204
                                                                                                   46.0
                                                                                                                                                                             32.0
                                 1.0 3.0
                                                2.0
                                                         33.0
                                                                    25.0
                                                                                40.0
                                                                                                                   38.0
                                                                                                                           38.0
                                                                                                                                       45.0 ...
                                                                                                                                                      55.0
                                                                                                                                                                    41.0
               18205
                                 1.0
                                       3.0
                                                2.0
                                                         34.0
                                                                    44.0
                                                                                50.0
                                                                                                   39.0
                                                                                                                   42.0
                                                                                                                            40.0
                                                                                                                                       51.0
                                                                                                                                                      50.0
                                                                                                                                                                    46.0
                                                                                                                                                                              20.0
               18206
                                1.0 3.0 2.0 33.0
                                                                    41.0
                                                                                34.0
                                                                                                   46.0
                                                                                                                   48.0
                                                                                                                           30.0
                                                                                                                                       43.0 ...
                                                                                                                                                      33.0
                                                                                                                                                                   43.0
                                                                                                                                                                             40.0
              18207 rows × 38 columns
```







```
In [18]: data[data['Jersey Number'].isnull()]
     Out[18]:
                          Unnamed:
                                            ID
                                                      Name Age
                                                                                                        Photo Nationality
                                                                                                                                                         Flag Overall Potential
                   5018
                                5018 153160 R. Raldes 37 https://cdn.sofifa.org/players/4/19/153160.png Bolivia https://cdn.sofifa.org/flags/53.png
                                                                                                                                                                    70
                                                                                                                                                                               70
                    6736
                                6736 175393
                                                     J. Arce 33 https://cdn.sofifa.org/players/4/19/175393.png
                                                                                                                     Bolivia https://cdn.sofifa.org/flags/53.png
                                                                                                                                                                     68
                                                                                                                                                                                68
                    7922
                               7922 195905 L. Gutiérrez 33 https://don.sofifa.org/players/4/19/195905.png Bolivia https://don.sofifa.org/flags/53.png
                                                                                                                                                                67
                    9905
                                                             23 https://cdn.sofifa.org/players/4/19/226044.png
                                                                                                                                                                                80
                                9905 226044
                                                 R. Vargas
                                                                                                                               https://cdn.sofifa.org/flags/53.png
                   10628
                              10628 216751 D. Bejarano 26 https://cdn.sofifa.org/players/4/19/216751.png Bolivia https://cdn.sofifa.org/flags/53.png 65
                                                                                                                                                                                66
                               13236 177971 J. McNulty 33 https://cdn.sofifa.org/players/4/19/177971.png
                                                                                                                                                                     62
                                                                                                                                                                                62
                                                                                                                                                                                       Ro
                   13236
                                                                                                                  Scotland https://cdn.sofifa.org/flags/42.png
                               13237 195380 J. Barrera 29 https://odn.sofifa.org/players/4/19/195380.png Nicaragua https://odn.sofifa.org/flags/88.png
                                                                                                                                                                                62
                   13237
                   13238
                               13238 139317 J. Stead 35 https://cdn.sofifa.org/players/4/19/139317.png
                                                                                                                  England https://odn.sofifa.org/flags/14.png
                                                                                                                                                                     62
                                                                                                                                                                                62
                              13239 240437 A. Semprini 20 https://cdn.sofifa.org/players/4/19/240437.png Italy https://cdn.sofifa.org/flags/27.png
                  13239
                                                                                                                                                                     62
                                                                                                                                                                                72
                                                                                                                                                                                         E W
4
     In [19]: flt_index = data[data['Jersey Number'].isnull()].index
                  flt_index
    Out[19]: Int64Index([ 5018, 6736, 7922, 9905, 10628, 13236, 13237, 13238, 13239, 13240, 13241, 13242, 13243, 13244, 13245, 13246, 13247, 13248,
                                 13249, 13250, 13251, 13252, 13253, 13254, 13255, 13256, 13257, 13258, 13259, 13251, 13252, 13253, 13254, 13255, 13256, 13257, 13258, 13259, 13260, 13261, 13262, 13263, 13264, 13265, 13266, 13267, 13268, 13269, 13270, 13271, 13272, 13273, 13274, 13275, 13276, 13277, 13278, 13279, 13280, 13281, 13282, 13283, 16450,
                                16539, 16793, 17129, 17339, 17436, 17539], dtype='int64')
     In [20]: data[data.index.isin(flt_index)]
     Out[20]:
                          Unnamed:
                                                     Name Age
                                                                                                        Photo Nationality
                                                                                                                                                          Flag Overall Potential
                                5018 153160
                                                R. Raldes
                                                               37 https://cdn.sofifa.org/players/4/19/153160.png
                                                                                                                      Bolivia https://cdn.sofifa.org/flags/53.png
                    6736
                                6736 175393
                                                     J. Aroe
                                                              33 https://cdn.sofifa.org/players/4/19/175393.png
                                                                                                                               https://cdn.sofifa.org/flags/53.png
                                                                                                                                                                                68
                                                                                                                      Bolivia
                    7922
                               7922 195905 L. Gutiérrez 33 https://cdn.sofifa.org/players/4/19/195905.png
                                                                                                                  Bolivia https://cdn.sofifa.org/flags/53.png
                                                                                                                                                                67
                                                                                                                                                                                67
                    9905
                                9905 226044
                                                 R. Vargas
                                                             23 https://cdn.sofifa.org/players/4/19/226044.png
                                                                                                                     Bolivia
                                                                                                                               https://cdn.sofifa.org/flags/53.png
                                                                                                                                                                     66
                                                                                                                                                                                69
                   10628
                               10628 216751 D. Bejarano 26 https://cdn.sofifa.org/players/4/19/216751.png
                                                                                                                                                                    65
                                                                                                                                                                                66
                                                                                                                    Bolivia https://cdn.sofifa.org/flags/53.png
                                                               33 https://cdn.sofifa.org/players/4/19/177971.png
                                                                                                                                                                     62
                                                                                                                                                                                62
                   13236
                               13236 177971
                                                 J. McNulty
                                                                                                                    Scotland
                                                                                                                               https://cdn.sofifa.org/flags/42.png
                                                                                                                                                                                       E
Ch
                   13237
                               13237 195380 J. Barrera 29 https://cdn.sofifa.org/players/4/19/195380.png Nicaragua https://cdn.sofifa.org/flags/86.png
                                                                                                                                                                     62
                                                                                                                                                                                62
```

J. Stead 35 https://cdn.sofifa.org/players/4/19/139317.png

13239 240437 A. Semprini 20 https://odn.sofifa.org/players/4/19/240437.png ltaly https://odn.sofifa.org/flags/27.png 62 72 E ▼

62

62

England https://cdn.sofifa.org/flags/14.png

13238

13238 139317

```
In [21]: data_num[data_num.index.isin(flt_index)]['Jersey Number']
              5018
6736
Out[21]:
                         NaN
NaN
             7922
9905
10628
13236
                         NaN
NaN
NaN
NaN
              13237
13238
                         NaN
NaN
              13239
13240
                         NaN
NaN
              13240
13241
13242
13243
13244
13245
13246
                         NaN
NaN
NaN
NaN
                         NaN
NaN
              13247
13248
                         NaN
NaN
              13249
                         NaN
In [22]: data_num_Jersey_Number = data_num[['Jersey Number']]
data_num_Jersey_Number.head()
Out[22]:
                   Jersey Number
              0 10.0
                                7.0
               2
                               10.0
               3
                                1.0
               4
                                7.0
In [24]: from sklearn.impute import SimpleImputer from sklearn.impute import MissingIndicator
In [25]: indicator = MissingIndicator()
    mask_missing_values_only = indicator.fit_transform(data_num_Jersey_Number)
    mask_missing_values_only
Out[25]: array([[False],
                        [False],
[False],
                         ...,
[False],
                        [False],
[False]])
In [26]: strategies=['mean', 'median', 'most_frequent']
```

```
In [31]: def test_num_impute(strategy_param):
                                       imp_num = SimpleImputer(strategy=strategy_param)
data_num_imp = imp_num.fit_transform(data_num_Jersey_Number)
                                        return data_num_imp[mask_missing_values_only]
In [28]: strategies[0], test_num_impute(strategies[0])
Out[28]: ('mean'
                              ('mean', array([19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19.54609577, 19
In [29]: strategies[1], test_num_impute(strategies[1])
Out[29]: ('median'
                                In [30]: strategies[2], test_num_impute(strategies[2])
Out[30]: ('most_frequent',
                               Обработка пропусков в категориальных данных
In [34]: cat_cols = []
                            cat_cois = []
for col in data.columns:
    # Κοπυνεσπβο ηνςπωχ βπανεμιὔ
temp_null_count = data[data[col].isnull()].shape[0]
dt = str(data[col].dtype)
                                         if temp_null_count>0 and (dt=='object'):
                                                   cat_cols.append(col)
                                                    cac_off.cappend(cdr)
temp_perc = round((temp_null_count / total_count) * 100.0, 2)
print('Колонка {}. Тип данных {}. Количество пустых значений {}, {}%.'.format(col, dt, temp_null_count, temp_perc))
```

```
In [35]: cat_temp_data = data[['Preferred Foot']]
cat_temp_data.head()
Out[35]:
Preferred Foot
                      Right
           2
                    Right
           3
                      Right
                  Right
In [36]: cat_temp_data['Preferred Foot'].unique()
Out[36]: array(['Left', 'Right', nan], dtype=object)
In [40]: cat_temp_data[cat_temp_data['Preferred Foot'].isnull()].shape
Out[40]: (48, 1)
In [41]: imp2 = SimpleImputer(missing_values=np.nan, strategy='most_frequent')
data_imp2 = imp2.fit_transform(cat_temp_data)
data_imp2
...,
['Right'],
['Right'],
['Right']], dtype=object)
In [42]: np.unique(data_imp2)
Out[42]: array(['Left', 'Right'], dtype=object)
In [43]: imp3 = SimpleImputer(missing_values=np.nan, strategy='constant', fill_value='!!!')
data_imp3 = imp3.fit_transform(cat_temp_data)
          data_imp3
...,
['Right'],
                  ['Right'],
['Right']], dtype=object)
In [44]: np.unique(data_imp3)
Out[44]: array(['!!!', 'Left', 'Right'], dtype=object)
```

```
In [45]: data_imp3[data_imp3=='!!!'].size
Out[45]: 48
```

```
Преобразование категориальных признаков в числовые
In [46]: cat_enc = pd.DataFrame({'c1':data_imp2.T[0]})
        cat_enc
Out[46]:
         0 Left
            1 Right
         2 Right
             3 Right
         4 Right
         18202 Right
          18203 Right
         18204 Right
          18205 Right
         18206 Right
         18207 rows × 1 columns
         label encoding
In [47]: from sklearn.preprocessing import LabelEncoder, OneHotEncoder
In [48]: le = LabelEncoder()
cat_enc_le = le.fit_transform(cat_enc['c1'])
In [49]: cat_enc['c1'].unique()
Out[49]: array(['Left', 'Right'], dtype=object)
In [50]: np.unique(cat_enc_le)
Out[50]: array([0, 1])
```

In [52]: le.inverse_transform([0, 1])
Out[52]: array(['Left', 'Right'], dtype=object)

one-hot encoding

7 Right8 Right9 Right

```
In [53]: ohe = OneHotEncoder()
cat_enc_ohe = ohe.fit_transform(cat_enc[['c1']])
In [54]: cat_enc.shape
Out[54]: (18207, 1)
In [55]: cat_enc_ohe.shape
Out[55]: (18207, 2)
In [56]: cat_enc_ohe
Out[56]: <18207x2 sparse matrix of type '<class 'numpy.float64'>'
with 18207 stored elements in Compressed Sparse Row format>
In [57]: cat_enc_ohe.todense()[0:10]
Out[57]: matrix([[1., 0.],
                       [[1, 0.],

[0., 1.],

[0., 1.],

[0., 1.],

[0., 1.],

[0., 1.],

[0., 1.],

[0., 1.],

[0., 1.],
In [58]: cat_enc.head(10)
Out[58]:
             0 Left
             1 Right
             2 Right
             3 Right
             4 Right
             5 Right
             6 Right
```


Масштабирование данных

In [59]: from sklearn.preprocessing import MinMaxScaler, StandardScaler, Normalizer


MinMax масштабирование

```
In [66]:
sc1 = MinMaxScaler()
sc1_data = sc1.fit_transform(data[['Age']])
```

```
In [67]: plt.hist(data['Age'], 50)
plt.show()
```



```
In [68]: plt.hist(sc1_data, 50)
plt.show()
```



Масштабирование данных на основе Z-оценки

Нормализация данных


```
In [72]: sc3 = Normalizer() sc3_data = sc3.fit_transform(data[['Age']])

In [73]: plt.hist(sc3_data, 50) plt.show()

17500 - 12500 - 12500 - 10000 - 7500 - 10000 - 7500 - 10000 - 7500 - 10000 - 7500 - 10000 - 7500 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000 - 10000
```

Violin plot

```
In [75]: sns.violinplot(x=data['Age'])
Out[75]: <matplotlib.axes._subplots.AxesSubplot at 0x1e268785888>
```



Для количественных признаков использовался метод импутации. Для категориальных признаков использовались методы label encoding и one-hot encoding. Для дальнейшего построения ММО буду использовать метод Pandas get_dummies для категориальных признаков и импьютацию для числовых, так как pandas get dummies является быстрым вариантом one-hot кодирования, а импьютация меньше влияет на данные в целом и не изменит размер датасета по сравнению с удалением или заполнением нулями. Для масштабирования были использованы MinMax масштабирование и масштабирование данных на основе Z-оценки.